

# Team08 : Asakatsu2025

---

静岡大学大木研究室

牧野由\*, 金杰, 徳増真大, 濱本柊弥

PWSCUP2025 2025年10月29日

# 本戦



コンペの本質に気づき始めた瞬間

# 本戦匿名化

---

# 匿名化データ

Biの匿名化データ (Ci) として別のBiを利用してみる




```
stats_diff max_abs: 0.08120000000000001  
LR_asthma_diff max_abs: 0.7895516086487742  
KW_IND_diff max_abs: 0.027706633257359614  
Ci utility: 60.40683516187732 / 80
```

スコア計算結果

攻撃してみても1000件程度しか当たらない

...なんか知らんけど意外と**有用性が高くて匿名性が高いデータ**が作成できた

# 配布データ生成に関する考察




## 配布データ生成に関する考察

配布されたそれぞれのBiは一つのデータから抽出されたものと考えることができる



配布データを匿名データとして利用した場合、正解データと不正解データに引き寄せられる確率はランダムになる




**Syntheaで匿名化データを作成**しちゃえば元データを推定できないのでは？

# 有用性と匿名性の理論値について

有用性と匿名性がともに高いCiは作成可能か？



Ai-Biのデータ  
(9万行)



1万行を抽出

stats\_diff max\_abs: 0.050680942122713846  
LR\_asthma\_diff max\_abs: 0.20957576750061846  
KW\_IND\_diff max\_abs: 0.02362126705166423  
**Ci utility: 73.30882162404579 / 80**

Ai-BiからCiを作成した結果

外れデータに対してハミング距離が0のデータ（距離ベースの攻撃ができない）  
を利用してCiを作成した場合でも、高い有用性スコアが得られる

# 有用性と匿名性の理論値について

## 攻撃されない匿名化データは最強なのか？

攻撃箇所をランダムに選択した場合、**10分の1で攻撃**できる

攻撃を行い、攻撃スコアが0の場合は**残りの9万件**に対してランダムに攻撃することで単純なランダムより多く攻撃されてしまう

## 一方で...

ランダムな攻撃が行われない場合、**攻撃方法に規則性**が生まれるため、敵チームに**攻撃されてしまう箇所が集中**してしまう可能性がある


敵チームに**ランダムな攻撃を誘導できる程度の匿名性**を保つことで  
より高い総合スコアが見込めると思われる

# LRスコアについて

LRスコアでは学習と評価でデータが分割される  
分割方法を変更するとスコアも変化

stats\_diff max\_abs: 0.0  
LR\_asthma\_diff max\_abs: 0.0  
KW\_IND\_diff max\_abs: 0.0  
Ci utility: 80 / 80

元データ同士の比較



シャッフル

stats\_diff max\_abs: 6.5503158452884236e-15  
LR\_asthma\_diff max\_abs: **0.6954712266555703**  
KW\_IND\_diff max\_abs: 0.0  
Ci utility: 66.09057546688834 / 80

シャッフル後データとの比較

LRスコアはデータの配置を変更するだけで向上させることができる



# 本戦の匿名化手法

予備戦終了時に配布された**全チームのAi（Syntheaデータ）**を利用



BBiとデータ分布が近いAiを採用，AiからBBiに対して**距離が近い1万行を除外**



残りの9万行から**有用性スコア（stats+KW）が高くなるように1万行を採用**



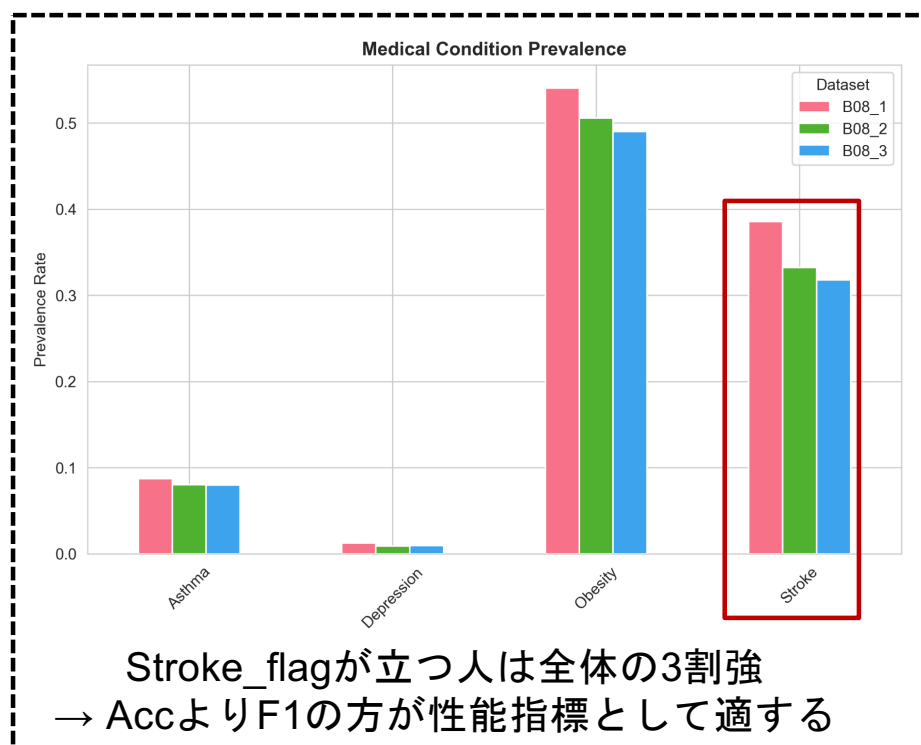
**データをシャッフル**し続けることでLRスコアを最大化

# 脳卒中リスク予測モデルの構築

Syntheaで独自に生成した200,000件の合成データで学習する

→ **Bi**を用いないため、モデルベースの攻撃が困難に

Biを検証データとして最もF1 Scoreが高いモデルを採用



## Biによる評価

Validation Accuracy: **0.890**

Validation F1 Score: 0.848

Validation AUC: 0.954

本戦の匿名化指標においても  
**17.75点**(Accuracy = 0.888を達成)

7手法のアンサンブル

## 本戦攻撃

---

# 攻撃手法

各チームの匿名化に合わせて異なる攻撃手法を採用

## 距離ベース

### データ拡張による攻撃

チーム内ベストスコア

Team 2, 3, 5, 7, 9, 12, 14, 15, 16, 17, 18, 22, 23, 24

**Team 14**

に対して**Top-1スコア**を達成！

### マハラノビス距離+ハンガリアン法

チーム内ベストスコア

Team 13

## モデルベース

### XGBoostの予測損失を用いた攻撃

チーム内ベストスコア

Team 4, 6

### Gaussian LiRA<sup>[1]</sup>の適用

チーム内ベストスコア

Team 1, 10, 11, 19, 20

**Team 1, 10, 11, 19, 20**

に対して**Top-1スコア**を達成！

## 距離ベース：データ拡張による攻撃

statsによる有用性評価ではピアソン相関を採用しているため、  
**共分散** $(x - \bar{x})(y - \bar{y})$ の値に近いほど有用性に対する貢献度が類似する

AGE	encounter_ count	...	mean_ weight
5	2	...	10.0
3	6	...	8.0
10	1	...	8.0
...	...	...	...
2	1	...	2.0



AGE_ encounter_count	AGE_ num_procedures	...	mean_bmi_ Mean_weight
-20	30	...	20.2
15	20	...	-40.8
-5	-10	...	25.4
...	...	...	...
-10	15	...	-30.0

共分散に基づいて、数値列の組み合わせからデータ拡張を行う（AGEも数値として扱う）

**拡張した各データ行**から距離が近いデータ行を探索して10000行を推定する

# 距離ベース：ハンガリアン法による最適割当

## 目的

### 最適割当

Aから抽出した1万件とCの全体の距離を最小化

## 前処理

数値列を0~1に正規化

カテゴリ列をOne-hotエンコーディングで0,1に変換

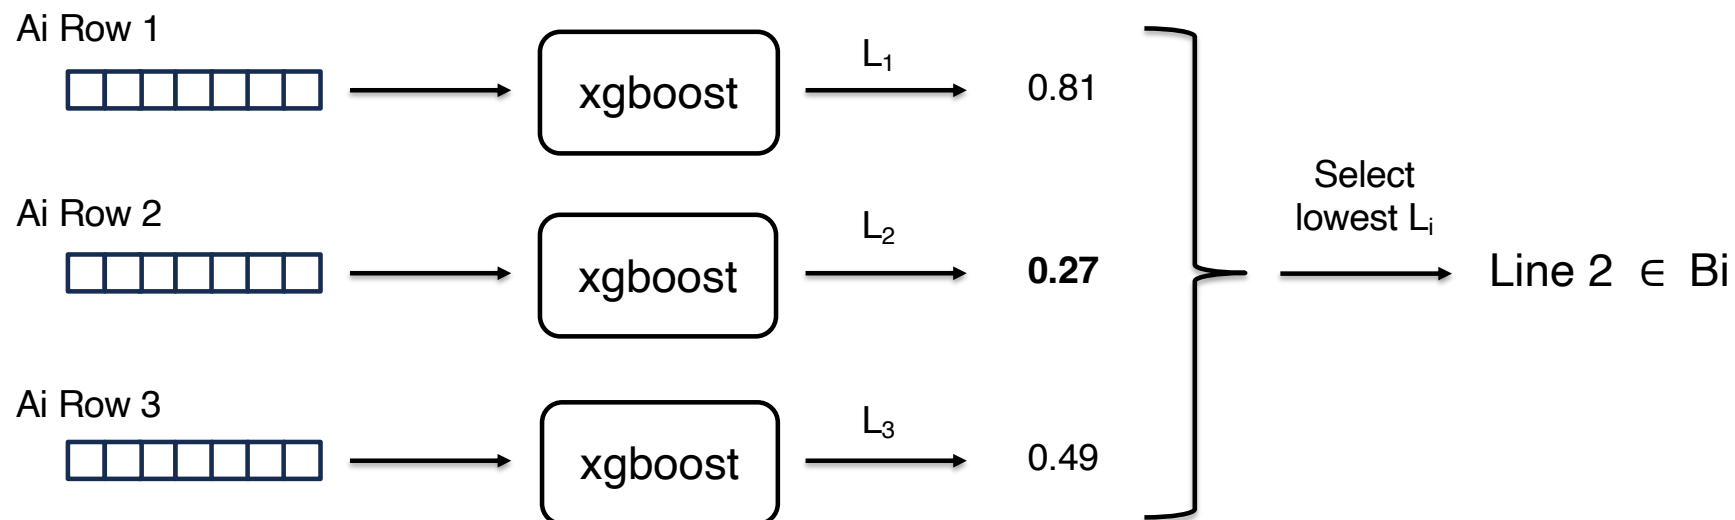
AとCの全ての組み合わせに対して距離 $d(A_iC_j)$ を計算

	$C_1$	$C_2$	...	$C_{10000}$
$A_1$	$d(A_1C_1)$	$d(A_1C_2)$	...	$d(A_1C_{10000})$
$A_2$	$d(A_2C_1)$	$d(A_2C_2)$	...	$d(A_2C_{10000})$
...	...	...	...	...
$A_{100000}$	$d(A_{100000}C_1)$	$d(A_{100000}C_2)$	...	$d(A_{100000}C_{10000})$

距離の合計が最小になるようにCの各レコードとAの各レコードを重複なしで割当

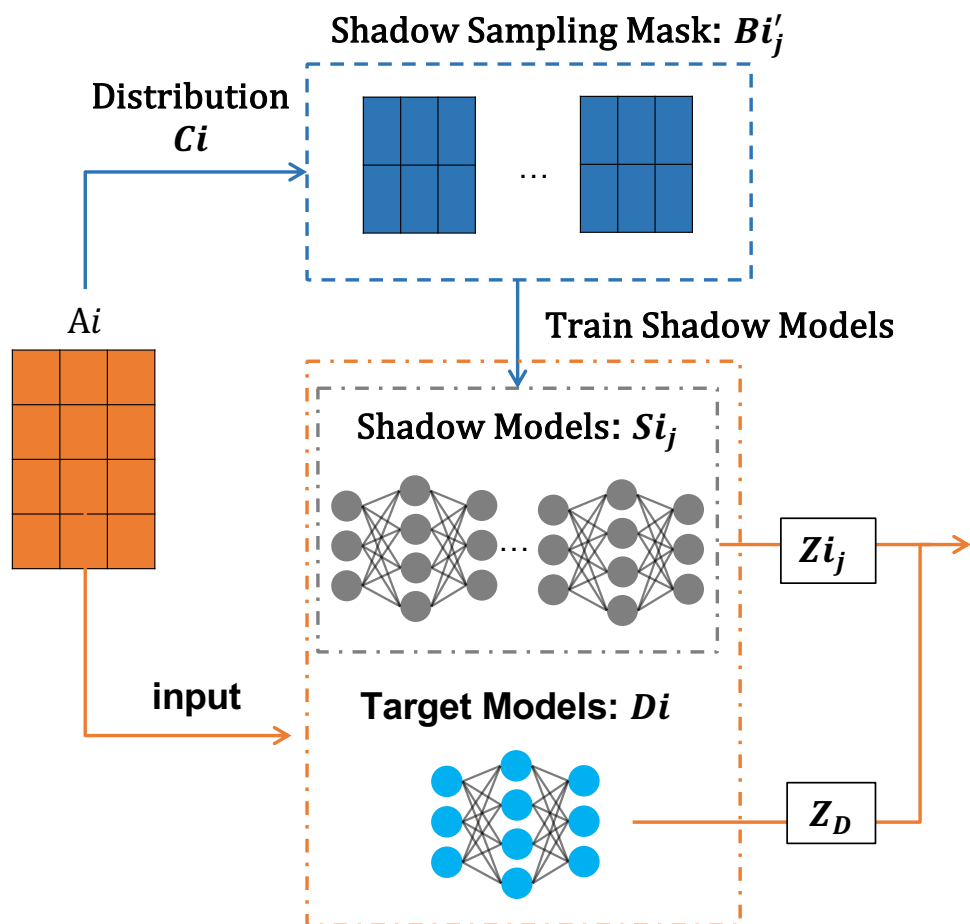
## 機械学習モデルベース：予測損失を用いた手法

XGBoostの学習に $B_i$ のレコードが使われていた場合、  
他レコードよりも予測損失  $L_i$  が小さくなる傾向がある可能性が高い



XGBoostモデルの予測損失が小さいAiの上位10,000件を選択

# XGBoost + Gaussian LiRA の理論構造



## Logit 定義

$Z_{i_j}$ : 各シャドウモデルのロジット

$Z_D$ : ターゲットモデルのロジット

## IN / OUT 定義

IN:  $B_i'$  を学習に含むシャドウモデル群

OUT:  $B_i'$  を学習に含まないシャドウモデル群

## Gaussian 近似パラメータ

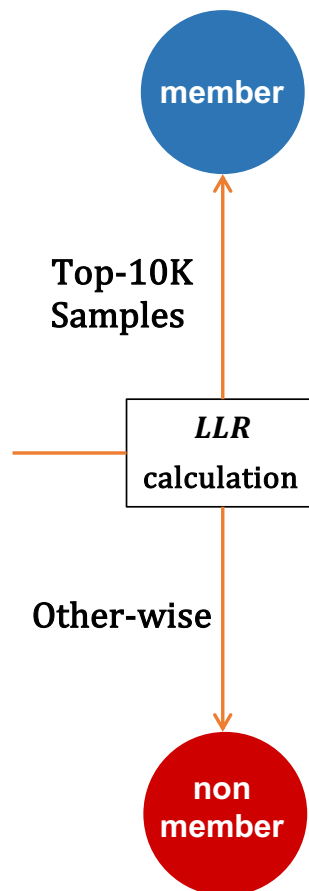



$\mu_{IN}, \mu_{OUT}$ : IN/OUT 群それぞれのロジット値  $\overline{Z_{i_j}}$

$\sigma_{IN}, \sigma_{OUT}$ : IN/OUT 群のロジット値の標準偏差

## IN / OUT 分布の対数尤度比 $LLR_i$

入力データの「学習データらしさ」を示す指標

$$LLR = \log \frac{\sigma_{OUT}}{\sigma_{IN}} \frac{(Z_D - \mu_{OUT})^2}{2\sigma_{OUT}^2} \frac{(Z_D - \mu_{IN})^2}{2\sigma_{IN}^2}$$





# 攻撃リザルト

各チームに対する攻撃結果として

攻撃性能top1 : 6チーム

攻撃性能top5 : 17チーム

のスコアを獲得！

モデルベースによる攻撃が結果に大きく貢献し、  
攻撃総合スコアで1位を達成！！！！！！

チーム番号	攻撃スコア	攻撃方法	攻撃順位
チーム1	1,653	モデルベース	1位
チーム2	1,070	距離ベース	8位
チーム3	1,313	距離ベース	6位
チーム4	1,011	モデルベース	10位
チーム5	1,366	距離ベース	4位
チーム6	1,065	モデルベース	2位
チーム7	1,097	距離ベース	4位
チーム8			
チーム9	1,247	距離ベース	2位
チーム10	1,379	モデルベース	1位
チーム11	1,668	モデルベース	1位
チーム12	1,069	距離ベース	3位
チーム13	1,030	距離ベース	8位
チーム14	5,536	距離ベース	1位
チーム15	1,495	距離ベース	3位
チーム16	1,040	距離ベース	11位
チーム17	4,522	距離ベース	2位
チーム18	1,030	距離ベース	5位
チーム19	1,289	モデルベース	1位
チーム20	1,343	モデルベース	1位
チーム21			
チーム22	3,161	距離ベース	5位
チーム23	1,123	距離ベース	2位
チーム24	7,379	距離ベース	2位